

Autoencoder

Se tiene una función que trata de aprender una aproximación a la función de identidad, es decir una red neuronal que genera un vector $\hat{\mathbb{X}}_i$ que sea similar al vector de entrada \mathbb{X}_i .




Figura 1. Red neuronal de un autoencoder

sea el vector de dato de entrada, $\mathbb{X}_i = \begin{pmatrix} \mathbb{X}_{1i} \\ \mathbb{X}_{2i} \\ \vdots \\ \mathbb{X}_{pi} \end{pmatrix}$

sea el vector de salida de la capa oculta, $\mathbb{Z}_i = \begin{pmatrix} \mathbb{Z}_{1i} \\ \mathbb{Z}_{2i} \\ \vdots \\ \mathbb{Z}_{pi} \end{pmatrix}$

Se tiene entonces la matriz de pesos de los datos de entrada $W_{cxp} = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1p} \\ w_{21} & w_{22} & \cdots & w_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ w_{c1} & w_{c2} & \cdots & w_{cp} \end{pmatrix}$

sea f una funcion de activacion lineal, $\mathbb{Z}_i = f(W\mathbb{X}_i)$

por ello se tiene $\mathbb{Z}_i = W\mathbb{X}_i$

Para el vector de datos estimados $\hat{\mathbb{X}}_i$, se tiene v matriz de pesos de la salida de la capa oculta y g una función de activación lineal:

$$\hat{\mathbb{X}}_i = g(vf(W\mathbb{X}_i)) \quad g \text{ y } f \text{ al ser lineales}$$

$$\text{Entonces: } \hat{\mathbb{X}}_i = VW\mathbb{X}_i \quad (1)$$

Definimos una función de costo: $J = \frac{1}{N} \sum_{i=0}^{N-1} |\hat{\mathbb{X}}_i - \mathbb{X}_i|^2$ y reemplazamos $\hat{\mathbb{X}}_i$ de (1)

$$J = \frac{1}{N} \sum_{i=0}^{N-1} |VW\mathbb{X}_i - \mathbb{X}_i|^2$$

Se optimiza la función de costo obtenida:

$$\begin{aligned} \nabla J(VW) &= \frac{1}{N} 2 \sum_{i=0}^{N-1} |VW\mathbb{X}_i - \mathbb{X}_i|^2 \mathbb{X}_i = 0 \\ &= \left(\frac{1}{N} 2 \sum_{i=0}^{N-1} |\mathbb{X}_i|^2 \right) |VW - I| = 0 \end{aligned}$$

Para que la expresión anterior se cumpla, se debe encontrar los vectores y valores propios de la siguiente expresión:

$$|VW - I| = 0$$

$$|\lambda VW - I\lambda| = 0 \quad (2)$$

Análisis de componentes principales (PCA)

En el análisis de componentes principales se busca reducir la dimensión de un conjunto \mathbb{X}_{pi} de variables, conservando la mayor cantidad de información que sea posible:

$$\mathbb{X}_{pi} \rightarrow \mathbb{Z}_{ci} \quad \text{donde } c < p$$

Sea entonces la A matriz de componentes principales

$$\mathbb{Z}_i = A\mathbb{X}_i$$

Y de este modo se tiene el vector de componentes principales \mathbb{Z}_i :

$$\mathbb{Z}_i = \begin{pmatrix} \hat{a}_1 \mathbb{X}_i \\ \hat{a}_2 \mathbb{X}_i \\ \vdots \\ \hat{a}_c \mathbb{X}_i \end{pmatrix} = \begin{pmatrix} \mathbb{Z}_1 \\ \mathbb{Z}_2 \\ \vdots \\ \mathbb{Z}_c \end{pmatrix}$$

Tomamos la componente de mayor variabilidad

$$\mathbb{Z}_1 = \hat{a}_1 \mathbb{X}_i$$

Encontramos su varianza:

$$var(\mathbb{Z}_1) = var(\hat{a}_1 \mathbb{X}_i)$$

$$var(\mathbb{Z}_1) = \hat{a}_1^t \Sigma \hat{a}_1$$

Donde \hat{a}_1 ortogonal y Σ la matriz de varianzas-covarianzas

$$\hat{a}_1^t \hat{a}_1 = 1$$

Para analizar la varianza del vector aplicamos los multiplicadores de LaGrange:

$$L(\hat{a}) = a^t \Sigma a - \lambda(a^t a - 1), a^t a = |a|^2$$

Y de este modo encontrar la máxima varianza derivamos los multiplicadores de LaGrange e igualamos 0.

$$\begin{aligned} \frac{\partial L(\hat{a})}{\partial \hat{a}} &= 2\Sigma a - 2\lambda a = 0 \\ &= 2(\Sigma - \lambda I)a = 0 \end{aligned}$$

De este modo la expresión anterior se cumple, encontrando los vectores y valores propios de la siguiente expresión

$$\Sigma - \lambda I = 0 \quad (3)$$

Se puede observar que para el autoencoder aprenda una aproximación a la función de identidad, se debe encontrar los pesos de la expresión (2) y de forma similar para el PCA exista una reducción de dimensión de los datos de entrada, se calculan los valores y vectores de (3), los cuales son análogos con los pesos encontrados en (2).